

# ZNEUS – PROJEKT1 – ADRIAN URBANEK

## Predikcia median\_house\_value

### HOUSES

Dátový zdroj: dataset s 20 640 riadkami a 9 číselnými stĺpcami; bez chýbajúcich hodnôt a bez duplicitných riadkov. Cieľ **median\_house\_value**, 965 hodnôt je cenzorovaných na maxime 500 001.

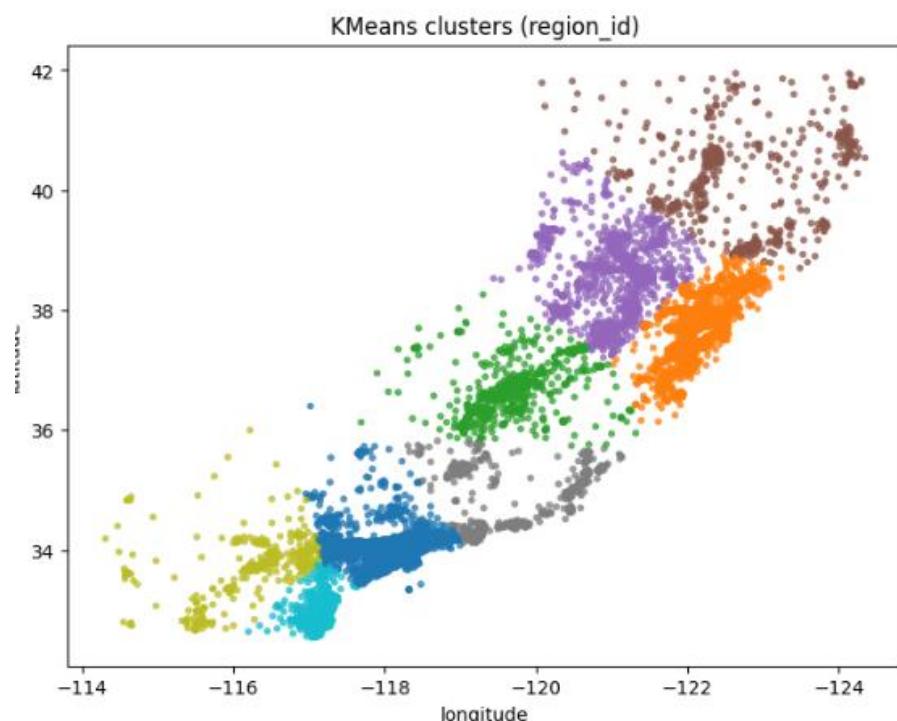
### 1) Zhrnutie dát a motivácia

- Pracujem s čisto numerickými premennými: príjem, vek bývania, izby/ložnice/populácia/gospodárstva, zemepisná šírka/dĺžka. Základné štatistiky potvrdzujú veľký rozptyl cieľa. Najsilnejší lineárny signál voči cieľu má median\_income (~0.69). Viaceré „count“ premenné majú vysokú šíklosť (skew) a ďažké chvosty

```
Top features by absolute correlation with target:  
median_income      0.688075  
latitude          0.144160  
total_rooms        0.134153  
housing_median_age 0.105623  
households         0.065843  
total_bedrooms     0.050594  
longitude          0.045967  
population         0.024650  
Name: median_house_value, dtype: float64
```

```
skew = num.skew().sort_values(ascending=False)  
display(skew)  
  
population           4.935858  
total_rooms          4.147343  
total_bedrooms       3.453073  
households           3.410438  
median_income        1.646657  
median_house_value   0.977763  
latitude             0.465953  
housing_median_age   0.060331  
longitude            -0.297801  
dtype: float64
```

- V EDA som si všimol výrazný priestorový vzor (KMeans k≈8 nad lat/lon vytvára regióny s rôznymi mediánmi), preto som do neskorších experimentov pridal geo-features



## 2) Základný pipeline (spoločný pre všetky experimenty)

### 1. Split (80/10/10) s kvantilovou stratifikáciou na cieľ

```
Train: (16512, 8), Val: (2064, 8), Test: (2064, 8)
```

### 2. Výber a príprava vstupov:

- 8 numerických stĺpcov (viď vyššie).
- Vybrané stĺpce so  $|skew| \geq 1 \rightarrow \log1p$  (počítané len na TRAIN).
- StandardScaler (fit len na TRAIN).

```
Target: median_house_value
Počet numerických features: 8
Features: ['median_income', 'housing_median_age', 'total_rooms', 'total_bedrooms', 'population', 'households', 'latitude', 'longitude']

def suggest_log_cols(frame: pd.DataFrame, cols: list[str], skew_threshold: float = 1.0) -> list[str]:
    skew_vals = frame[cols].skew(numeric_only=True)
    return skew_vals[skew_vals.abs() >= skew_threshold].index.tolist()

def make_preprocess(feature_cols: list[str], log_cols: list[str] | None = None):
    if log_cols is None:
        log_cols = []
    other_cols = [c for c in feature_cols if c not in log_cols]

    col_tf = ColumnTransformer(
        transformers=[
            ("log", FunctionTransformer(np.log1p, validate=False), log_cols),
            ("num", "passthrough", other_cols),
        ],
        remainder="drop"
    )
    preprocess = Pipeline([
        ("cols", col_tf),
        ("scaler", StandardScaler()),
    ])
    return preprocess

LOG_COLS_SUGGESTED = suggest_log_cols(df, FEATURES_NUM, skew_threshold=1.0)
print("Návrh log1p stĺpcov (na celej vzorke):", LOG_COLS_SUGGESTED)

Návrh log1p stĺpcov (na celej vzorke): ['median_income', 'total_rooms', 'total_bedrooms', 'population', 'households']
```

### 3. Model: MLP pre tabuľkové dátá (PyTorch), s možnosťou:

- BatchNorm, Dropout, bottleneck, reziduálne bloky

### 4. Tréning:

- Optimizer Adam (používal som aj RMSprop/SGD v searchoch)
- ReduceLROnPlateau na validačný loss
- Early stopping podľa validačného lossu
- Grad clipping a weight decay (pri niektorých nastaveniach)
- AMP na GPU (rýchlosť/nízka pamäť)

**Anti-overfit opatrenia:** train-only fit (log1p/scaler), validácia oddelená od testu, early stopping, dropout, weight decay.

**Anti-underfit:** adekvátna kapacita MLP, batch-norm, jemné dolaďovanie LR a batch size.

### 3) Prehľad experimentov

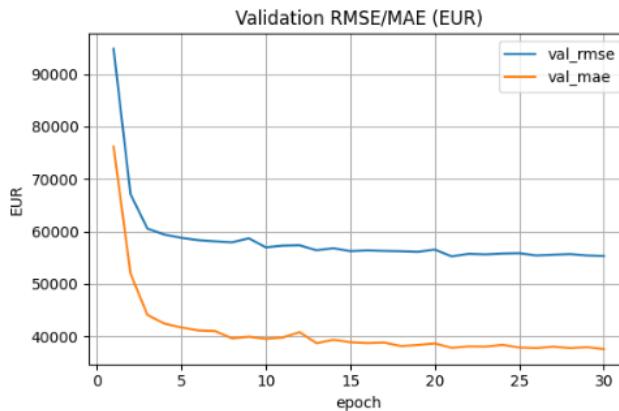
#### EXPERIMENT 1 — All + (log1p na šikmé)

##### Čo som spravil

- Vstupy len 8 numerických stípcov (bez akýchkoľvek geografických konštruktov).
- log1p na stípcach s  $|skew| \geq 1$  (typicky: median\_income, total\_rooms, total\_bedrooms, population, households).
- Štandardizácia, MLP [256,128,64], BN + Dropout  $\sim 0.10$ , Adam  $1e-3$ , early stopping.

##### Ako to dopadlo (približne)

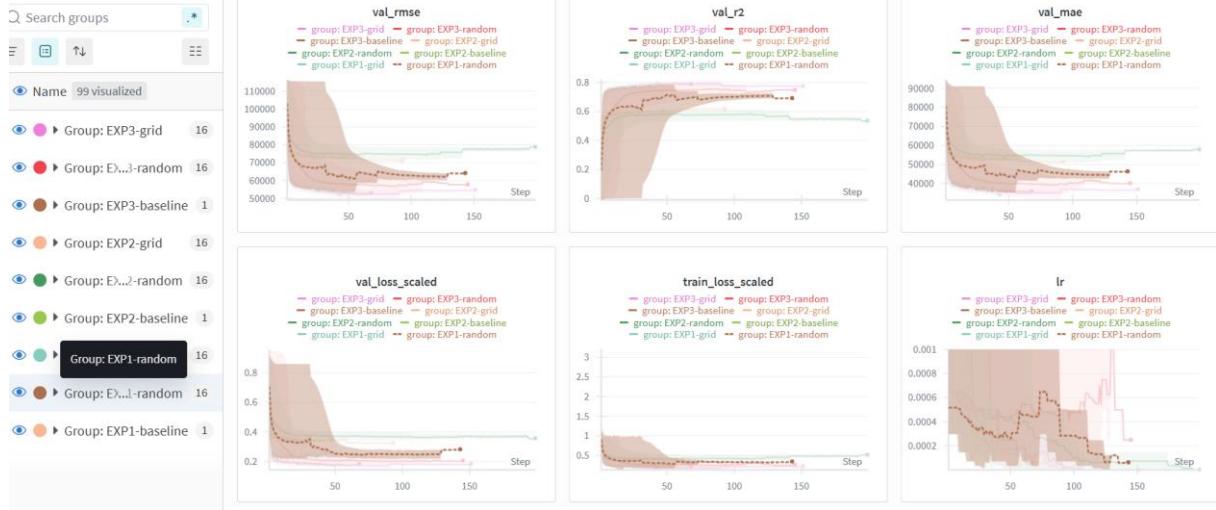
- Výsledky: **Train**  $\sim 54k$ , **Val**  $\sim 57k$  /  $\sim 40k$  MAE /  $R^2 \sim 0.75\text{--}0.76$ , **Test**  $\sim 57k$  /  $\sim 40k$  MAE /  $R^2 \sim 0.75$
- Test  $\approx$  Val  $\rightarrow$  stabilné, ale bez extra presnosti



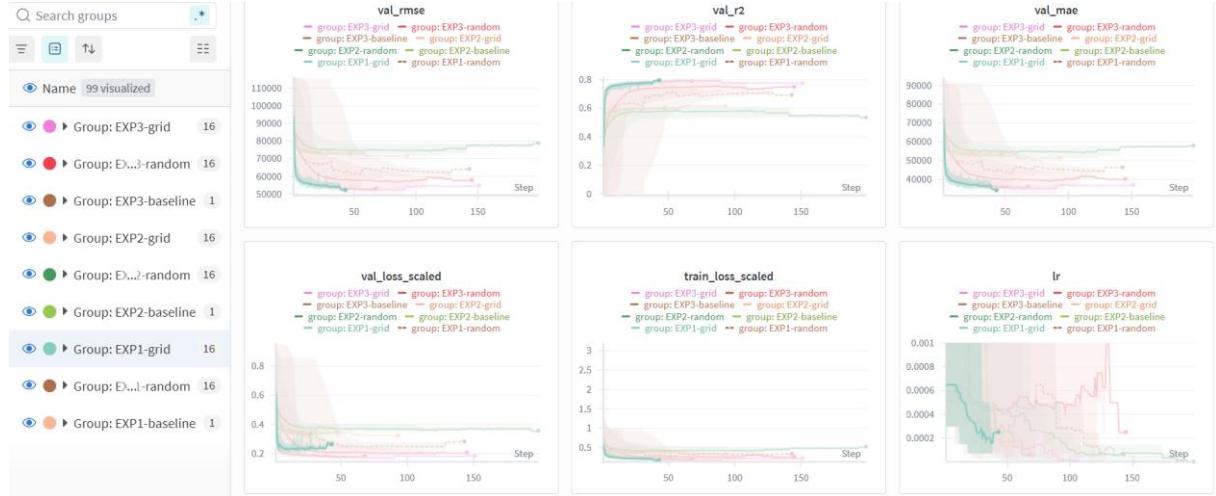
```
] print(pd.DataFrame(res_baseline).round(4))  
      train    val    test  
rmse  54497.3398  57005.7695  57039.6641  
mae   38448.7500  39567.6328  39544.8516  
r2     0.7771      0.7575      0.7529
```

## WANDB:

### RANDOM:



### GRID:



## EXPERIMENT 2 — Výber najlepších vstupov podľa |corr|

### Čo som spravil

- Na **TRAIN** som vypočítal korelácie všetkých kandidátov s cieľom a vybral **Top-4** stĺpce podľa  $|corr|$
- Na tieto Top-4 som opäť aplikoval log1p podľa šikmosti a následne škálovanie
- Model MLP ako v EXP1; skúšal som aj **random/grid search** nad architektúrou a tréningom

```

TOP4_E2 = corr_tbl.abs().sort_values(ascending=False).head(4).index.tolist()
print("EXP2 Top-4 (TRAIN |corr|):", TOP4_E2)

EXP2 Top-4 (TRAIN |corr|): ['median_income', 'latitude', 'total_rooms', 'housing_median_age']

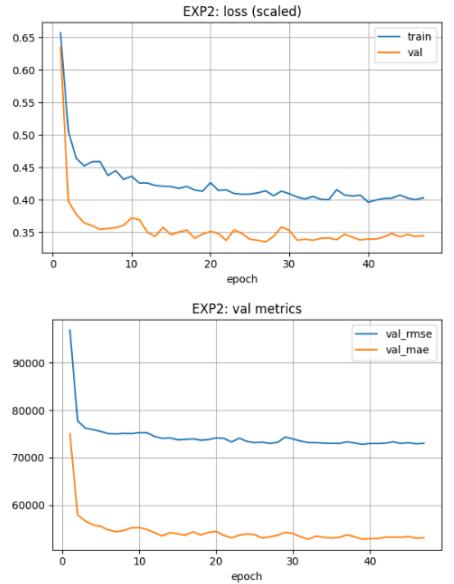
LOG_E2 = X_train2[TOP4_E2].skew(numeric_only=True).abs().pipe(lambda s: s[s >= 1.0].index.tolist())
print("EXP2 log_cols (TRAIN):", LOG_E2)

EXP2 log_cols (TRAIN): ['median_income', 'total_rooms']

```

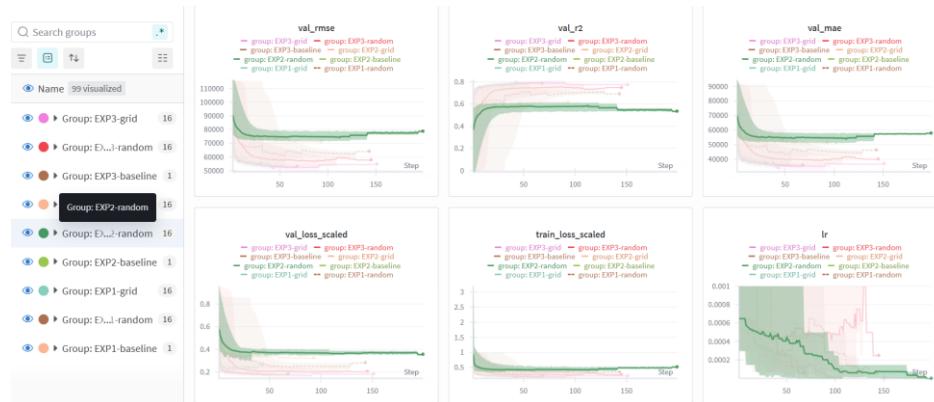
## Ako to dopadlo (pribežne)

- Train ~71k, Val ~73k / ~53k MAE / R<sup>2</sup> ~0.60, Test ~75k / ~55k MAE / R<sup>2</sup> ~0.57
- Možeme sledovať zhorenie vs. EXP1, malý „priestorový kontext“

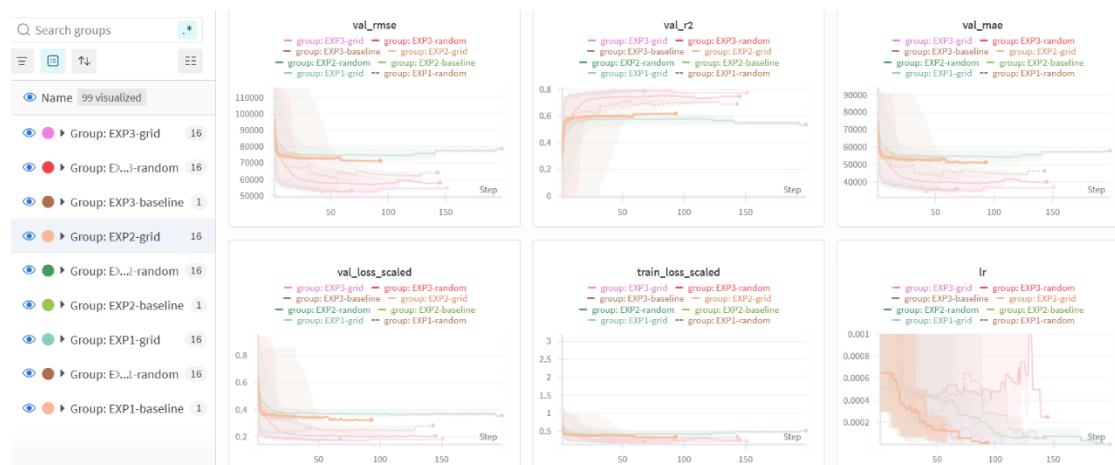


WANDB:

Random:



GRID:



## EXPERIMENT 3 — Geografické bloky + štatistiky regiónov (najlepší)

### Čo som spravil

- Z latitude/longitude som cez **KMeans (K=8)** vytvoril **regióny**
- Do vstupov som pridal:
  - **one-hot** region\_0..region\_7,
  - regionálne **štatistiky z TRAIN**: region\_mean (priemerná cena), region\_size (počet vzoriek), region\_rank (percentil priemeru),
  - **interakcie/polynómy**: income\_lat, income\_lon, lat2, lon2, lat\_lon
- Celé som prehnal cez rovnaký preprocess (train-only log1p + scaler)
- Model MLP s BN/Dropout. Následne **random search** a **grid** okolo top nastavení

### Najlepšia konfigurácia (grid)

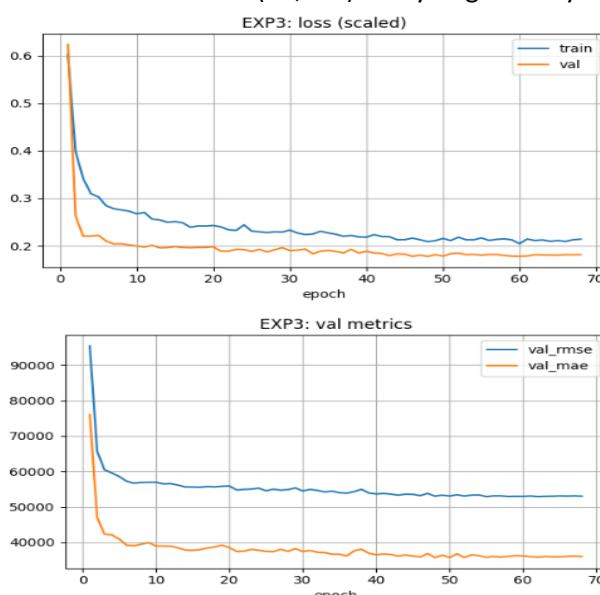
- **Layers**: [256,128,64]
- **BatchNorm**: True, **Dropout**: ~0.10
- **Optimizer**: Adam, **LR**: 1e-3, **Weight decay**: 1e-5
- **Batch**: 1024, **Patience**: ~16, **Grad clip**: 1.0
- *Feature set*: exp3\_all\_geo

### Ako to dopadlo

- Najlepšie: **Val ~49–50k, Test ~49–50k.**

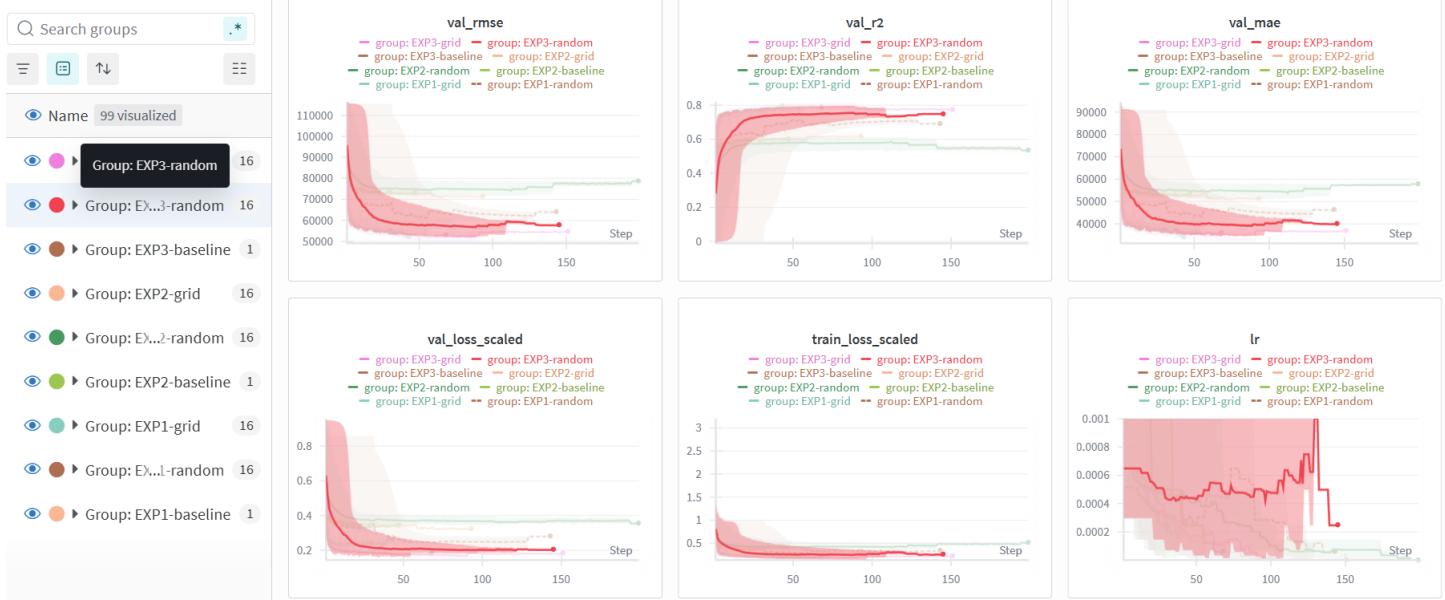
### Ako to pomohlo(regiony)

- Regióny a ich štatistiky dopĺňajú čisté súradnice o „lokálny kontext trhu“ (priemy, veľkosť klastru, ranking)
- Interakcie income × (lat, lon) zachytia gradienty cien po mape

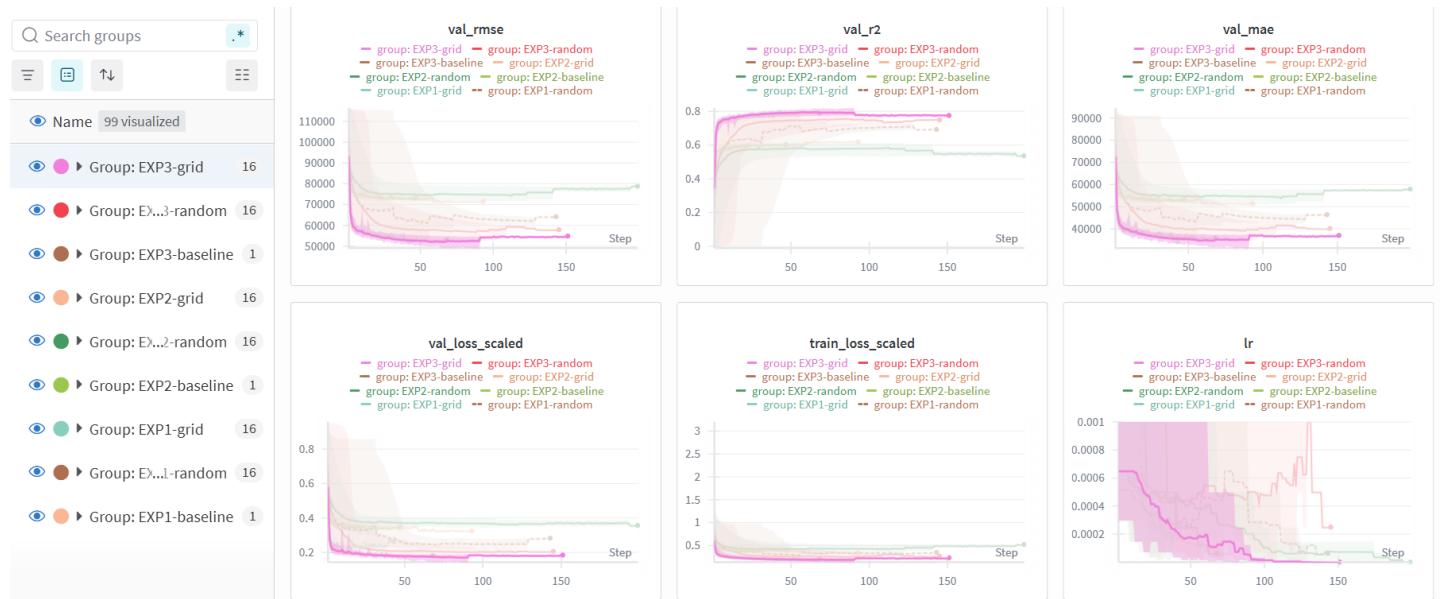


## WANDB:

### Random:



### GRID:



## 4) Porovnanie experimentov

### EXP1 (random)

	trial	val_rmse	val_mae	val_r2	test_rmse	test_mae	test_r2
0	8	54791.94	36329.73	0.78	55026.29	36033.54	0.77
1	13	56024.22	38416.66	0.77	56216.36	38533.17	0.76
2	4	56549.23	37687.66	0.76	56517.07	37022.33	0.76
3	5	56928.77	39401.02	0.76	57257.67	39558.74	0.75
4	6	57498.70	38930.01	0.75	57413.57	38688.31	0.75
5	2	57740.38	39894.01	0.75	57926.43	39826.64	0.75
6	12	57604.21	39773.11	0.75	58262.83	39658.39	0.74
7	3	57445.81	39754.99	0.75	58305.04	39170.13	0.74
8	9	58617.56	40584.36	0.74	58840.70	40284.08	0.74
9	10	59225.02	41836.99	0.74	59555.50	41653.15	0.73
10	1	59660.49	42130.79	0.73	59867.79	41748.04	0.73
11	14	60425.13	42679.32	0.73	61060.25	42353.48	0.72
12	16	61474.27	43886.78	0.72	61827.71	43887.54	0.71
13	7	63054.42	44005.96	0.70	63059.09	43192.93	0.70
14	15	64632.85	46823.05	0.69	65196.39	47210.70	0.68
15	11	115792.25	90481.38	-0.00	114748.84	89724.23	-0.00

### EXP2 (random)

i	val_rmse	test_rmse	val_mae	test_mae	cfg
12	13	71835.086	74327.703	51693.031	53171.566 ('seed': 9065, 'hidden_layers': [256, 128, 64], ...)
7	8	72054.359	74699.164	51976.797	53540.156 ('seed': 1313, 'hidden_layers': [256, 128, 64], ...)
10	11	72479.062	74782.102	52424.629	53674.266 ('seed': 3493, 'hidden_layers': [256, 128, 64], ...)
3	4	72665.438	74784.359	52597.496	53724.598 ('seed': 3007, 'hidden_layers': [256, 128, 64], ...)
5	6	72186.891	74867.141	52246.438	53532.004 ('seed': 6210, 'hidden_layers': [256, 128, 64], ...)
11	12	72363.711	74871.070	51527.621	53107.270 ('seed': 8901, 'hidden_layers': [256, 128, 64], ...)
14	15	72876.375	75064.609	52569.480	53867.004 ('seed': 7240, 'hidden_layers': [256, 128, 64], ...)
6	7	73293.875	75098.992	53534.516	54463.727 ('seed': 3567, 'hidden_layers': [256, 128, 64], ...)
2	3	72951.438	75746.203	53243.148	54508.277 ('seed': 1613, 'hidden_layers': [256, 128, 64], ...)
8	9	72767.305	75867.297	52201.207	54089.820 ('seed': 6869, 'hidden_layers': [256, 128, 64], ...)

### EXP3 (grid)

i	val_rmse	test_rmse	val_mae	test_mae	val_r2	test_r2
0	1	49233.66	49306.96	31749.07	31401.44	0.82
1	3	50715.01	50760.66	33081.49	33030.86	0.81
2	5	51744.96	51395.43	34778.08	34327.30	0.80
3	4	52063.84	52132.87	34464.29	34116.51	0.80
4	7	51887.34	52412.87	34846.62	34927.98	0.80
5	11	52925.28	52535.75	35500.35	35339.98	0.79
6	8	53047.28	52831.57	35405.67	35539.93	0.79
7	13	53262.09	53074.62	36198.43	36407.70	0.79
8	2	53228.40	53156.32	35860.56	35745.72	0.79
9	15	53242.44	53259.51	35997.20	36169.20	0.79
						0.78

Najlepší grid podľa test\_rmse:

```
{'seed': 43, 'hidden_layers': [256, 128, 64], 'batchnorm': True, 'dropout': 0.05, 'residual': False, 'bottleneck': True, 'optimizer': 'adam', 'lr': 0.001, 'weight_decay': 1e-05, 'batch_size': 1024, 'epochs': 200, 'patience': 16, 'grad_clip': 1.0, 'feature_set': 'exp3_allnum_geo'}
```

## 5) Rozhodnutie o finálnom modeli

**EXP3 (grid-tuned MLP)** som vybral ako finálny, pretože konzistentne dosahuje najnižšie validačné aj testovacie chyby a najvyššie R<sup>2</sup>

Dôležitým faktorom je **stabilita** (val ≈ test), dobré krvky konvergencie a rozumná jednoduchosť nasadenia (MLP bez ľažkých embedov)

## 6) Reprodukcia a technické poznámky

- **Seed:** 42 (a pevné seedy pre NumPy/PyTorch)
- **Fit len na TRAIN:** všetky transformácie (log1p, imputácia, scaler)
- **Saving:** model/artefakty len ak je to povolené (v mojom finále som ich neukladal, W&B slúži ako história)
- **Hardvér:** GPU (AMP), batch 1024
- **Tréning:** Early stopping + ReduceLROnPlateau, grad clipping 1.0, patience ~16

## 7) Záver

- Najväčší skok priniesli **geografické reprezentácie** (EXP3)
- Finálny EXP3-MLP (grid-tuned) má **~49–52k RMSE** na VAL/TEST pri **MAE ~34–36k** a **R<sup>2</sup> ~0.75–0.80**
- Krivky a metriky naznačujú **dobrú generalizáciu** a nízke riziko overfittingu